

Klasifikacija sorti pasulja primenom algoritma k najbližih suseda i analize glavnih komponenti

Aleksandar Horvat

Dunja Tomašević

June 20, 2026

1 Uvod i opis skupa podataka

Predmet analize je *Dry Bean Dataset*, koji sadrži 16 numeričkih obeležja izvedenih iz slika zrna sedam sorti pasulja (**Barbunya**, **Bombay**, **Cali**, **Dermason**, **Horoz**, **Seker**, **Sira**). Obeležja opisuju geometrijske karakteristike poput površine, obima, dužine glavne i sporedne ose, ekscentriciteta, okruglosti i nekoliko izvedenih faktora oblika. Cilj rada je razvoj i evaluacija klasifikatora koji na osnovu ovih obeležja predviđa sortu pasulja, kao i ispitivanje uticaja redukcije dimenzionalnosti na kvalitet klasifikacije.

Nakon učitavanja podataka utvrđeno je da skup ne sadrži nedostajuće vrednosti, dok je pronađen mali broj duplikata koji je uklonjen iz daljeg razmatranja.

2 Eksplorativna analiza podataka

Analiza zastupljenosti klasa pokazala je da skup nije savršeno balansiran – odnos najbrojnije i najmanje zastupljene klase iznosi oko 6.8, što je razlog da se pored tačnosti prate i dodatne metrike (preciznost, odziv, F_1 skor) koje su informativnije u prisustvu disbalansa klasa.

Ispitivanjem distribucija pojedinačnih obeležja uočeno je da dimenzijski atributi (**Area**, **Perimeter**, **MajorAxisLength**, **MinorAxisLength**, **ConvexArea**, **EquivDiameter**) pokazuju izraženu pozitivnu asimetriju sa dugim desnim repom, dok pojedina obeležja oblika (**AspectRatio**, **Eccentricity**, **ShapeFactor2**) imaju bimodalan karakter. Ovakvi oblici raspodela su značajni jer i PCA i kNN mogu biti osetljivi na ekstremne vrednosti – PCA jer se zasniva na kovarijansnoj matrici koju ekstremne vrednosti mogu narušiti, a kNN jer autlajeri direktno utiču na glasanje suseda preko euklidske udaljenosti.

Korelaciona analiza pokazala je postojanje jasno izdvojenih grupa međusobno korelisanih obeležja: prvu čine dimenzijska obeležja koja u suštini mere veličinu zrna, drugu obeležja oblika poput ekscentriciteta i odnosa stranica, koja su negativno korelisana sa okruglošću i kompaktnošću, dok se uočava i grupa obeležja koja opisuju pravilnost oblika zrna. Obeležje **Extent** pokazalo se relativno nezavisnim od ostalih. Ovakva struktura korelacija predstavlja povoljnu polaznu osnovu za primenu PCA, jer ukazuje da bi mali broj komponenti mogao objasniti veći deo ukupne varijanse.

Analizom srednjih vrednosti standardizovanih obeležja po klasama, kao i grafičkim prikazom raspodela pomoću box-plotova, ustanovljeno je da klase nisu podjednako razdvojive. Sorta **Bombay** se izrazito izdvaja od ostalih sorti po dimenzijskim obeležjima i formira gotovo potpuno izolovan klaster, dok parovi sorti **Barbunya**–**Cali** i **Dermason**–**Sira** pokazuju vrlo slične profile obeležja, što ih unapred ukazuje kao potencijalno najteže za međusobno razlikovanje.

3 Analiza glavnih komponenti

Algoritam analize glavnih komponenti (engl. *Principal Component Analysis* - PCA) implementiran je bez korišćenja gotovih funkcija. Postupak obuhvata centriranje standardizovanih podataka, izračunavanje kovarijansne matrice, te dekompoziciju na sopstvene vrednosti i sopstvene vektore primenom funkcije `numpy.linalg.eigh`. Sopstveni vektori sortirani su opadajuće po pripadajućim sopstvenim vrednostima, čime je dobijen redosled glavnih komponenti u odnosu na količinu objašnjene varijanse.

Na osnovu kumulativne objašnjene varijanse utvrđeno je da su potrebne četiri glavne komponente kako bi se objasnilo najmanje 95% ukupne varijanse podataka, što predstavlja značajnu redukciju u odnosu na originalnih 16 obeležja. Ova odluka je dodatno potvrđena analizom greške rekonstrukcije u zavisnosti od

broja zadržanih komponenti – kriva greške naglo opada do četvrte komponente, nakon čega se praktično izravna, što ukazuje da dodatne komponente donose zanemarljiv doprinos.

Tumačenjem koeficijenata projekcije (engl. *loadings*) utvrđeno je fizičko značenje zadržanih komponenti: prva komponenta opisuje pre svega veličinu zrna, druga njegovu izduženost, treća nepravilnost konture (kroz obeležje *Solidity*), dok je četvrta dominantno određena obeležjem *Extent*, koje opisuje prostornu popunjenost zrna. Dvodimenzionalna i trodimenzionalna vizualizacija projekcije podataka na prve glavne komponente potvrdila je zapažanja iz eksplorativne analize – sorta *Bombay* ostaje jasno odvojena, dok se sorte *Barbunya*, *Cali*, *Dermason* i *Sira* značajno preklapaju.

Dodatno je ispitan uticaj logaritamske transformacije obeležja sa izraženom pozitivnom asimetrijom na rezultate PCA. Pokazano je da ovakva transformacija ne menja broj komponenti potrebnih za objašnjenje 95% varijanse, niti donosi suštinsko poboljšanje raspodele varijanse po komponentama, zbog čega je u daljoj analizi zadržana jednostavnija varijanta bez logaritamske transformacije.

4 Klasifikacija algoritmom k najbližih suseda

Algoritam k najbližih suseda (engl. *k Nearest Neighbours* - kNN) implementiran je takođe ručno, pri čemu se klasifikacija novog uzorka vrši na osnovu euklidske udaljenosti do svih uzoraka trening skupa, odabira k najbližih suseda i određivanja predviđene klase prostom većinom glasova.

Optimalna vrednost hiperparametra k određena je na zasebnom validacionom skupu, izdvojenom iz trening skupa. Ispitan je opseg neparnih vrednosti $k \in \{1, 3, 5, 7, 9, 11, 13, 15, 17, 19\}$, kako bi se izbegle nerešene situacije pri glasanju.

Klasifikator treniran nad svim standardizovanim originalnim obeležjima postigao je visoku tačnost na test skupu, uz makro i ponderisani prosek metrika koji su međusobno bliski, što ukazuje na stabilnost modela i pored prisutnog disbalansa klasa. Sorta *Bombay* klasifikovana je sa savršenom preciznošću i odzivom, dok su sorte *Sira* i *Dermason* pokazale najveći broj međusobnih pogrešnih klasifikacija, u skladu sa očekivanjima iz eksplorativne analize i PCA projekcija.

Primenom kNN algoritma nad podacima projektovanim u prostor glavnih komponenti (konkretno četiri glavne komponente) zabeležen je blag pad ukupne tačnosti u odnosu na model nad originalnim obeležjima, dok je broj potrebnih aritmetičkih operacija pri računanju udaljenosti znatno smanjen usled redukcije dimenzionalnosti sa 16 na 4 obeležja. Najizraženiji pad performansi zabeležen je kod sorti *Barbunya* i *Cali*, dok su sorte *Sira* i *Dermason* zadržale približno iste rezultate kao i pre primene PCA. Poređenjem modela sa dve, tri i četiri zadržane komponente pokazano je da tačnost raste sa brojem komponenti, ali da već tri komponente daju zadovoljavajuće rezultate uz mogućnost trodimenzionalne vizualizacije granica odlučivanja modela.

5 Klasifikacija algoritmom težinskih k najbližih suseda

Kako bi se ispitalo da li različit doprinos suseda može poboljšati klasifikaciju u oblastima gde dolazi do preklapanja klasa, implementirana je težinska varijanta algoritma k najbližih suseda (engl. *weighted kNN*). Za razliku od standardnog kNN algoritma, gde svaki od k najbližih suseda učestvuje u glasanju sa jednakom težinom, weighted kNN dodeljuje veći značaj bližim susedima, dok se uticaj udaljenijih suseda umanjuje. U ovom radu težina svakog suseda određena je kao recipročna vrednost njegove euklidske udaljenosti od posmatranog uzorka, pri čemu je za slučaj potpunog poklapanja uzorka ($d = 0$) predviđena posebna obrada, tako da se direktno dodeljuje klasa odgovarajućeg trening uzorka.

Optimalna vrednost hiperparametra k određena je na istom validacionom skupu korišćenom za standardni kNN, čime je omogućeno objektivno poređenje oba pristupa. Nakon izbora optimalnog parametra izvršena je evaluacija weighted kNN algoritma na originalnom prostoru obeležja, kao i na podacima projektovanim u prostor prve četiri glavne komponente.

Vredno je napomenuti da pronađena optimalna vrednost k nije ista za oba algoritma, niti u oba prostora obeležja. Na originalnim atributima weighted kNN bira veće k od standardnog kNN, u skladu sa intuicijom da ponderisanje smanjuje uticaj udaljenih suseda, dok se nakon primene PCA ovaj odnos menja. Ovakva situacija ukazuje da izbor optimalnog k zavisi od konkretnog prostora obeležja i ne sledi univerzalan obrazac.

Dobijeni rezultati pokazuju da ponderisanje suseda nije dovelo do poboljšanja klasifikacionih performansi. Na originalnom prostoru obeležja weighted kNN ostvaruje tačnost od 91.33%, što je neznatno manje u odnosu na standardni kNN (91.55%). Sličan odnos zadržava se i nakon primene PCA, gde weighted kNN takođe ne uspeva da nadmaši standardnu varijantu algoritma.

Detaljnija analiza metrika po klasama pokazuje da ponderisanje nije umanjilo problem preklapanja sorti *Barbunya-Cali* i *Sira-Dermason*. Kod pojedinih klasa vrednosti F_1 skora ostaju praktično nepromenjene, dok je kod ostalih zabeležen veoma blag pad. Sa druge strane, sorta *Bombay* zadržava gotovo savršenu klasifikaciju u svim razmatranim modelima, što potvrđuje da njena geometrijska izdvojenost predstavlja dominantan faktor uspešne klasifikacije, nezavisno od izbora algoritma.

Dodatno, ispitan je uticaj standardizacije podataka i izbora metrike rastojanja na uspešnost kNN algoritma. Pokazano je da standardizacija predstavlja neophodan korak, budući da algoritam zasniva klasifikaciju na rastojanjima između uzoraka, pa obeležja sa većim numeričkim opsegom mogu imati nesrazmerno veliki uticaj na donošenje odluke. Nužnost standardizacije se ogledala u značajnom padu tačnosti oba modela (i osnovne verzije i težinske verzije kNN algoritma), kada su primenjeni na originalne nestandardizovane podatke. Takođe su upoređene euklidska i Menhetn metrika, pri čemu je upotreba Menhetn udaljenost u sklopu kNN algoritma postigla zanemarljivo bolje klasifikacione performanse, kako kod standardnog, tako i kod weighted kNN algoritma, takođe na originalnim podacima.

Na osnovu sprovedenih eksperimenata može se zaključiti da weighted kNN za ovaj skup podataka ne donosi praktičnu prednost u odnosu na standardni kNN algoritam. Dobijeni rezultati ukazuju da glavni uzrok grešaka nije način glasanja suseda, već značajno preklapanje pojedinih klasa u prostoru obeležja.

6 Zaključak i dalji pravac istraživanja

U ovom radu analiziran je problem klasifikacije sorti suvog pasulja primenom algoritma k najbližih suseda i analize glavnih komponenti. Tokom istraživanja sprovedena je detaljna eksplorativna analiza skupa podataka, implementirana analiza glavnih komponenti bez korišćenja gotovih bibliotekskih funkcija, kao i standardna i težinska varijanta kNN algoritma.

Rezultati pokazuju da standardni kNN primenjen nad originalnim standardizovanim obeležjima ostvaruje najbolje performanse, sa tačnošću od 91.55%. Primena PCA omogućila je redukciju dimenzionalnosti sa 16 na 4 obeležja uz zadržavanje najvećeg dela ukupne varijanse, pri čemu je zabeležen blag pad tačnosti od približno dva procentna poena. Iako redukcija dimenzionalnosti ne poboljšava klasifikacione performanse, ona značajno smanjuje broj operacija potrebnih za računanje euklidskih udaljenosti, čime doprinosi efikasnijem izvršavanju algoritma.

Dodatno je ispitana primena weighted kNN algoritma sa ciljem poboljšanja klasifikacije u oblastima preklapanja klasa. Međutim, eksperimentalni rezultati pokazuju da ponderisanje suseda ne donosi merljivo poboljšanje u odnosu na standardni kNN. Najveći broj pogrešnih klasifikacija i dalje se javlja između sorti *Barbunya* i *Cali*, odnosno *Sira* i *Dermason*, što ukazuje da uzrok grešaka prvenstveno leži u velikoj sličnosti njihovih karakteristika.

Kao mogući pravac budućih istraživanja izdvaja se primena Linearne diskriminantne analize (engl. *Linear Discriminant Analysis* - LDA) umesto analize glavnih komponenti. Za razliku od PCA, koja maksimizuje ukupnu varijansu podataka nezavisno od pripadnosti klasama, LDA koristi informacije o klasama kako bi maksimizovala njihovu međusobnu razdvojenost, što bi moglo doprineti boljoj klasifikaciji sorti koje se značajno preklapaju. Pored toga, umesto redukcije dimenzionalnosti putem PCA, vredelo bi bilo ispitati metode selekcije atributa, koje bi omogućile zadržavanje najinformativnijih originalnih obeležja uz eliminaciju redundantnih karakteristika.

S obzirom na izraženu korelisanost pojedinih atributa u posmatranom skupu podataka, dodatni pravac istraživanja predstavlja primena Mahalanobisove distance, budući da ova metrika uzima u obzir kovarijansnu strukturu podataka, koja bi mogla doprineti boljem razdvajanju međusobno sličnih sorti pasulja.